Classificação do Dataset Iris: Análise Exploratória, PCA e K-NN

Pedro Henrique Gurski de Oliveira
GRR: 20224759
pedrogurski@ufpr.br

Ulisses Curvello Ferreira
GRR: 20223829
ulissesferreira@ufpr.br

Curitiba, 17 de outubro de 2026

1 Introdução

Repositório do código: Acessar repositório no GitHub

Base de dados: Iris (UCI Machine Learning Repository)

Este trabalho utiliza o conjunto de dados *Iris*, publicado por Fisher em 1936 e disponibilizado no repositório de aprendizado de máquina da UCI. Ele reúne 150 flores, sendo 50 de cada uma de três espécies: `Iris-setosa`, `Iris-versicolor` e `Iris-virginica`. Cada flor é descrita por quatro medidas contínuas, em centímetros: comprimento e largura da sépala e comprimento e largura da pétala. Não há valores faltantes. Seguindo a observação da própria página da UCI, as amostras 35 e 38 foram corrigidas para os valores do artigo original de Fisher.

O objetivo é investigar como as classes se comportam nessas quatro dimensões e avaliar o quanto um classificador simples, o K-NN (*K-Nearest Neighbors*), consegue separá-las. O trabalho foi implementado em Python (`pandas`, `matplotlib` e `scikit-learn`) e segue as etapas: estatísticas descritivas, relações entre variáveis por classe, distribuição das classes, análise de componentes principais (PCA) e classificação com divisão de 80% para treino e 20% para teste.

2 Análise Exploratória

A Tabela 1 apresenta a média, o desvio padrão e a moda de cada variável, no conjunto completo e separadamente por classe. As três classes têm exatamente 50 amostras cada (33,3% do total), ou seja, o conjunto é perfeitamente balanceado, o que dispensa cuidados especiais com a escolha da métrica de avaliação.

Tabela 1: Média, desvio padrão e moda (em cm) de cada variável, no conjunto completo e por classe. Quando há empate, todas as modas são listadas.

Grupo	Variável	Média	Desvio	Moda
Geral	Comprimento da sépala	5,843	0,828	5,0
	Largura da sépala	3,057	0,436	3,0
	Comprimento da pétala	3,758	1,765	1,4 e 1,5
	Largura da pétala	1,199	0,762	0,2
Setosa	Comprimento da sépala	5,006	0,352	5,0 e 5,1
	Largura da sépala	3,428	0,379	3,4
	Comprimento da pétala	1,462	0,174	1,4 e 1,5
	Largura da pétala	0,246	0,105	0,2
Versicolor	Comprimento da sépala	5,936	0,516	5,5, 5,6 e 5,7
	Largura da sépala	2,770	0,314	3,0
	Comprimento da pétala	4,260	0,470	4,5
	Largura da pétala	1,326	0,198	1,3
Virginica	Comprimento da sépala	6,588	0,636	6,3
	Largura da sépala	2,974	0,322	3,0
	Comprimento da pétala	5,552	0,552	5,1
	Largura da pétala	2,026	0,275	1,8

Algumas observações já aparecem nessa tabela. As médias das medidas da pétala crescem de forma clara de setosa para versicolor e virginica (comprimento de 1,46 para 4,26 e 5,55 cm), enquanto a largura da sépala não segue essa ordem: a setosa tem as sépalas mais largas (3,43 cm) e a versicolor as mais estreitas (2,77 cm). Além disso, o desvio padrão geral das variáveis da pétala (1,765 e 0,762) é muito maior do que o desvio dentro de cada classe (entre 0,105 e 0,552). Isso indica que grande parte da variação total dessas variáveis vem da diferença entre as espécies, e não da variação dentro delas, o que as torna boas candidatas para separar as classes. Por fim, a moda geral coincide com a moda de alguma classe: por exemplo, o valor 0,2 cm para a largura da pétala é a moda da setosa, a classe mais compacta.

2.1 Relação entre comprimento e largura da sépala

Dentro de cada espécie, o comprimento e a largura da sépala têm correlação positiva (Figura 1a), mais forte na setosa ($r = 0{,}74$) do que na versicolor ($r = 0{,}53$) e na virginica ($r = 0{,}46$). No conjunto completo, porém, a correlação é ligeiramente *negativa* ($r = -0{,}12$). Trata-se do paradoxo de Simpson: a setosa tem sépalas curtas e largas, e as outras duas, longas e estreitas, o que inverte a tendência quando as classes são misturadas. A figura mostra ainda que a setosa fica isolada, enquanto versicolor e virginica se sobrepõem bastante.

2.2 Relação entre comprimento e largura da pétala

Na pétala (Figura 1b), a correlação geral é muito alta ($r = 0{,}96$), mas ela vem sobretudo da diferença entre as espécies, que se alinham em diagonal (pétalas pequenas, médias e grandes). Dentro de cada classe a relação é mais fraca: só a versicolor mantém correlação forte ($r = 0{,}79$), contra 0,33 na setosa e 0,32 na virginica. As pétalas da setosa são pequenas e variam pouco, e como as medidas têm resolução de 0,1 cm muitos pontos se sobrepõem. Versicolor e virginica se aproximam em torno de 5 cm de comprimento.

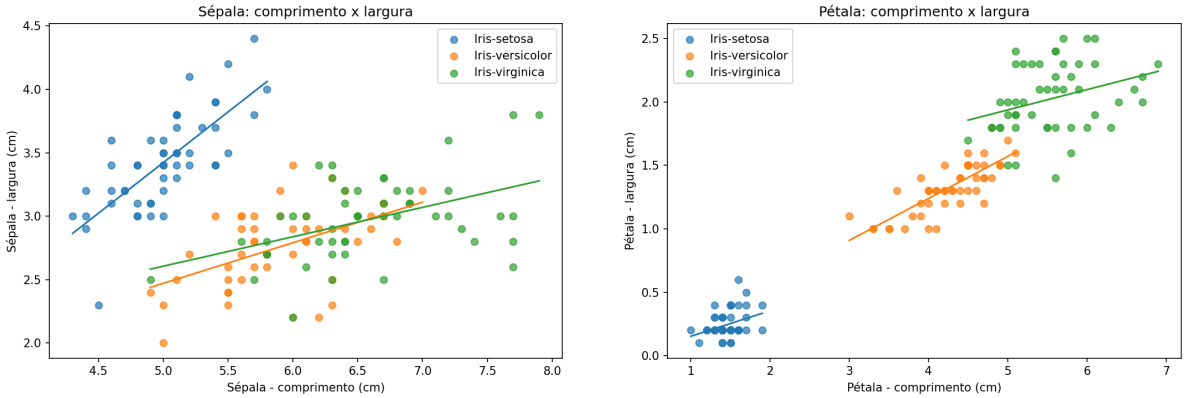


Figura 1: Comprimento × largura, com reta de regressão por classe (azul: setosa; laranja: versicolor; verde: virginica). (a) Sépala, à esquerda. (b) Pétala, à direita.

2.3 Distribuição das classes nas quatro dimensões

A Figura 2 mostra a distribuição de cada variável por classe. As variáveis da pétala são as que melhor separam as espécies: a setosa fica totalmente isolada (comprimento de pétala abaixo de 2 cm), e versicolor e virginica se sobrepõem pouco, em torno de 4,5 a 5,1 cm no comprimento e de 1,4 a 1,8 cm na largura. Isso se reflete na estatística F (variância entre classes sobre variância dentro das classes): 1180 para o comprimento e 960 para a largura da pétala, contra 119 e 49 para o comprimento e a largura da sépala. As medidas da sépala se sobrepõem bastante, principalmente a largura, em que versicolor e virginica são quase indistinguíveis. Assim, a setosa é separável das demais, e a dificuldade de classificação está em distinguir versicolor de virginica.

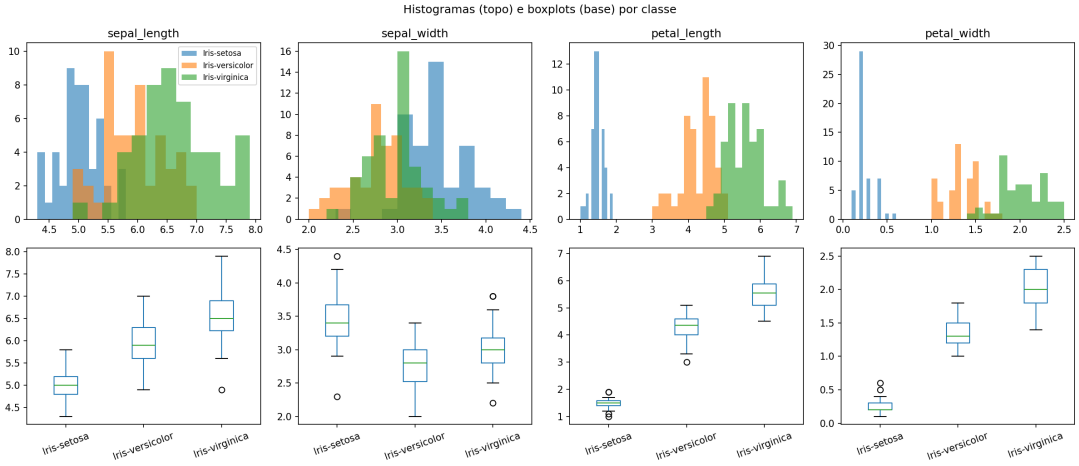


Figura 2: Histogramas (parte superior) e *boxplots* (parte inferior) de cada variável.

3 Análise de Componentes Principais (PCA)

O PCA encontra novos eixos, combinações lineares das variáveis originais, ordenados pela variância dos dados que explicam. Como as variáveis têm escalas diferentes, ele foi aplicado sobre os dados padronizados (Figura 3).

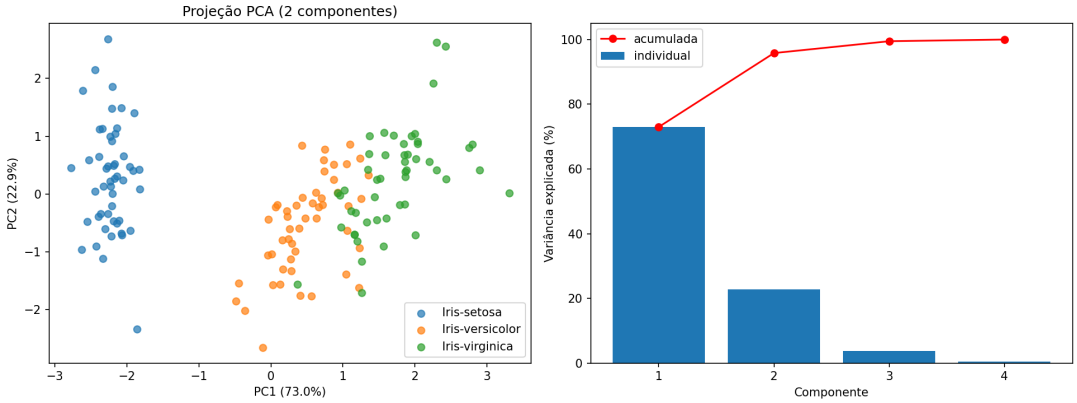


Figura 3: À esquerda, projeção das 150 amostras nos dois primeiros componentes principais (azul: setosa; laranja: versicolor; verde: virginica). À direita, variância explicada por componente (barras) e acumulada (linha vermelha).

O PC1 explica 73,0% da variância e o PC2, 22,9%; juntos somam 95,8%, então as quatro dimensões podem ser resumidas em duas com pouca perda de informação. Pelas cargas, o PC1 é um eixo de "tamanho geral" da flor, dominado pelas pétalas e pelo comprimento da sépala (cargas de 0,52 a 0,58), e o PC2 é dominado pela largura da sépala (carga de 0,92).

O PC1 praticamente sozinho separa as espécies: a setosa fica isolada à esquerda, e versicolor e virginica ocupam regiões vizinhas, com pequena sobreposição. O PC2 contribui pouco para separar as classes e reflete principalmente a variação interna de cada grupo. Isso mostra que o PCA, por ser não supervisionado, maximiza variância e não separação entre classes; aqui as duas coincidem em boa parte, mas isso não é garantido em geral.

4 Classificação com K-NN

O conjunto foi dividido em 80% para treino (120 amostras) e 20% para teste (30 amostras), com divisão estratificada, de modo que o teste tem 10 amostras de cada classe e as proporções originais são preservadas. As variáveis foram padronizadas dentro de um *pipeline*, ajustando a padronização (e, quando usado, o PCA) apenas com os dados de treino, para evitar vazamento de informação do conjunto de teste.

O hiperparâmetro k (número de vizinhos) foi escolhido por validação cruzada com 5 partições aplicada *somente* ao conjunto de treino, testando k de 1 a 25. A Figura 4 mostra o resultado.

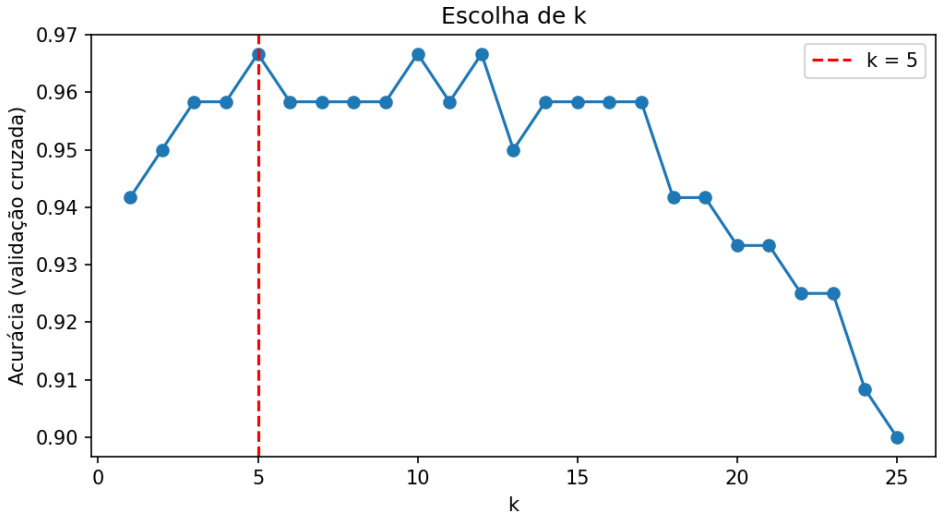


Figura 4: Acurácia média na validação cruzada (5 partições, apenas no treino) em função de k. A linha tracejada indica o valor escolhido, $k = 5$.

A acurácia na validação cruzada é alta para quase todos os valores de k. Com $k = 1$ ela é menor (cerca de 94%), pois o modelo fica sensível a ruído e a pontos isolados (sobreajuste). Ela atinge o máximo de 96,7% em $k = 5$, 10 e 12 e permanece em torno de 95% a 96% até $k = 17$. A partir de $k = 18$ a acurácia cai, chegando a 90% em $k = 25$, porque a vizinhança passa a ser tão grande que o modelo perde a capacidade de capturar as fronteiras entre as classes (subajuste). Como há empate entre vários valores, adotamos

o menor deles, $k = 5$, que resulta em um modelo mais simples e está em uma região estável da curva.

5 Conclusão

A análise mostrou que o dataset Iris é um problema de classificação simples, mas com uma dificuldade bem localizada. A setosa é completamente separável das demais, tanto nas análises gráficas quanto no K-NN, que a classificou sem erros em todos os experimentos. As variáveis da pétala são as mais informativas (estatística F de 1180 e 960, contra 119 e 49 da sépala), e a análise por classe revelou efeitos que a análise geral esconde, como a correlação negativa geral entre as medidas da sépala (paradoxo de Simpson) e a correlação alta entre as medidas da pétala, explicada em grande parte pela diferença entre as espécies.

O PCA indicou que dois componentes resumem 95,8% da variância e que o primeiro componente, um eixo de tamanho geral da flor, já separa bem as classes. O K-NN, com $k = 5$ escolhido por validação cruzada no treino, atingiu entre 90% e 100% de acurácia no teste, conforme as variáveis usadas, e cerca de 95% em média ao repetir a divisão 100 vezes. Todos os erros ficaram entre versicolor e virginica. Como o conjunto de teste é pequeno, recomenda-se avaliar o modelo com validação cruzada ou múltiplas divisões, e não confiar em uma única divisão para comparar configurações.